

Paper 2 초안: LLM-assisted MASEM-ready Extraction

팀 공유용 working draft | Research Synthesis Methods 방향 | 2026-05-30

핵심 메시지: Paper 2는 LLM이 인간을 대체하는지 평가하는 논문이 아니라, MASEM-ready extraction에서 LLM이 어떤 task family에서는 prefill/triage를 돕고, 어떤 task family에서는 expert adjudication이 필요한지를 검증하는 methods paper이다.

1. 논문 방향

현재 framing은 task-contingent LLM augmentation이다. 즉, LLM의 전체 정확도 하나를 보고 자동 대체 가능성을 주장하지 않는다. 대신 raw human-human disagreement, source-document adjudication, source-anchored adjudicated human reference standard, LLM comparison, downstream MASEM substitution stability를 순서대로 분리한다.

- RQ0: 인간 코더들이 adjudication 전에 어디서 왜 불일치하는가?
- RQ1: frozen human reference와 비교했을 때 LLM workflow가 task family별로 얼마나 정확한가?
- RQ2: 어떤 source format, construct ambiguity, sample definition이 오류를 설명하는가?
- RQ3: human disagreement와 LLM flags가 expert review triage에 도움이 되는가?
- RQ4: human-supervised LLM-assisted input이 MASEM pooled correlations/path conclusions를 보존하는가?

2. 현재까지 모인 데이터

데이터 상태	현재 값	의미
Validation corpus	213 studies	Phase 1+2 Paper B validation corpus
Phase 1	100 studies	Pair A(R1+R2) 50; Pair B(R3+R4) 50
Phase 2	113 studies	Pair C(R1+R4) 57; Pair D(R2+R3) 56
Calibration block	10 studies	training/calibration으로 별도 취급
Current adjudication stage	Step 3 active	source-document adjudication 진행 중; Step 4 reference freeze 전

Correlation review queue	164	source-type/numeric/coder-only issue가 있는 study-level review rows
--------------------------	-----	--

근거 파일: data/04_extraction/README.md; WORKFLOW_STATUS_LOG.md; combined_study_review_queue_20260525.csv; combined_correlation_review_queue_20260525.csv.

3. Pre-adjudication disagreement snapshot

구분	Count	해석
전체 disagreement rows	2949	source adjudication 전에 이미 상당한 review load가 존재
Metadata disagreement	1585	대부분은 표준화 가능하지만 sample/country/tool type은 moderator에 영향
Correlation disagreement	1364	MASEM matrix에 직접 연결되는 high-consequence layer
Numeric/source differences	734	r/beta/Fornell-Larcker/sample/source table 확인 필요
One-coder-only rows	630	한 코더만 evidence를 찾은 case; missingness와 source recovery issue

Phase	Pair	Studies	Disagreement rows
phase1	Pair A	50	972
phase1	Pair B	50	707
phase2	Pair C	57	720
phase2	Pair D	56	550

위 수치는 combined_pairwise_disagreement_summary_20260525.csv에서 산출했다.

4. 새 adjudication 기록 원칙

중요한 분리: consensus_source_value에는 PDF/source가 실제 보고한 값과 evidence type을 기록하고, analysis_note에는 그 값이 zero-order r, latent/Fornell-Larcker off-diagonal correlation, beta/path coefficient, HTMT-only, excluded row 중 무엇인지 표시한다.

- zero-order r 와 latent correlation은 downstream sensitivity에서 분리할 수 있도록 source type을 남긴다.
- standardized path coefficient 또는 beta-converted value는 correlation처럼 직접 섞지 않고, path/beta source로 표시한다.
- Fornell-Larcker diagonal, HTMT-only value, wrong sample/construct, untraceable source는 target MASEM correlation row로 자동 채택하지 않는다.
- source-check 결과가 exclude_row 또는 exclude_study이면 숫자 자체보다 exclusion rationale과 source location을 우선 기록한다.

5. 대략적인 결과 그림

주의: 아래는 현재 pre-adjudication evidence에 기반한 방향성이다. LLM accuracy, triage yield, substitution stability는 frozen human reference와 locked LLM outputs가 생긴 뒤에만 결과로 보고할 수 있다.

- RQ0 결과는 'MASEM-ready extraction은 trained human coders에게도 어려운 task family가 있다'는 것을 보여줄 가능성이 크다.
- metadata는 표준화 부담이 크지만 대체로 low consequence로 분류될 수 있다. 다만 country, education level, AI type은 moderator로 연결되므로 완전 자동화하면 안 된다.
- correlation/path recovery는 source-type confusion, one-coder-only evidence, Fornell-Larcker/HTMT 구분 때문에 expert adjudication required category가 많이 나올 가능성이 높다.
- LLM의 주된 기여는 final answer 자동 대체가 아니라 source span 찾기, structured prefill, human review queue prioritization일 가능성이 높다.
- 최종 Paper 2의 강점은 element-level accuracy보다 downstream inference stability를 같이 본다는 점이다.

6. 팀 공유용 결과 테이블 설계

Table	현재 채울 수 있는 내용	freeze 이후 채울 내용
Table 1: Dataset states	raw human data, pairwise diff data, adjudication status	frozen reference file/date
Table 2: Task taxonomy	bibliographic, sample, construct, numeric, matrix, moderator task families	task-family decision category calibration
Table 3: RQ0 disagreement	2,949 disagreement rows and pair/field breakdown	adjudicated resolution categories

Table 4: LLM validity	shell only	task-family LLM agreement/error metrics
Table 5: Substitution stability	shell only	pooled r/path/fit conclusion deltas

7. Stop rules for team communication

1. Step 4 reference freeze 전에는 LLM accuracy, model ranking, or substitution stability를 결과처럼 말하지 않는다.
2. path coefficient를 zero-order correlation과 같은 statistic으로 직접 비교하거나 섞지 않는다.
3. HTMT-only와 Fornell-Larcker diagonal은 MASEM correlation으로 쓰지 않는다.
4. raw coder disagreement는 지우지 않고 RQ0 evidence로 보존한다.
5. 최종 Word/논문 draft에는 source-anchored adjudicated human reference standard라는 용어를 사용하고 gold standard라는 표현은 피한다.

8. 다음 작업

6. combined_correlation_review_queue_20260525.csv에서 source-type mismatch와 one-coder-only cases를 먼저 adjudicate한다.
7. S014, S021, S056, S092, S121, S202 같은 include-candidate/review-source studies의 construct/sample/source-type 결정을 기록한다.
8. S195/S206 duplicate-source/exclusion decision은 final reference-freeze log에 반영한다.
9. reference freeze 후 LLM outputs를 열고 RQ1-RQ4 분석을 시작한다.
10. Paper 2 Methods 문단, Table 1-3, Figure 1 design flow는 지금부터 manuscript-ready로 작성 가능하다.